

SDR

Consensus

Raft

Olivier Lemer

↓ **Le principe**

Suppositions

Pas plus de $\lceil N/2 \rceil - 1$ pannes simultanées.

Pannes récupérables, sans amnésie.

Pas de duplication ou réordonnancement de messages.

Pertes possibles.

Réseau partiellement synchrone.

Réplication de machine d'état

Pensé pour répliquer une machine d'état sur chaque processus.

Un log répliqué

Chaque processus maintient un log des opérations à appliquer.

Un élu

Responsable de synchroniser ces logs répliqués.

Réplication de machine d'état

Pensé pour répliquer une machine d'état sur chaque processus.

Un log répliqué

Chaque processus maintient un log des opérations à appliquer.

Un élu

Responsable de synchroniser ces logs répliqués.

Deux responsabilités distinctes

Synchronisation des logs

Un consensus doit exister sur le contenu du log.

Élection d'un leader

Un élu mort doit être remplacé, et toute incohérence corrigée.

↓ Gestion des logs répliqués

Un élu responsable du log

Log vs Machine d'état

Deux concepts distincts

Le log d'opérations

Ce qui va être (ou a été) appliqué à la machine d'état

Chaque log peut donc être

- Committed (*appliqué*)
- Pending (*pas encore appliqué*)

La machine d'état elle-même

L'état actuel, après application de tous les logs committed.

Log vs Machine d'état

Deux concepts distincts

Le log d'opérations


Ce qui va être (ou a été) appliqué à la machine d'état

Chaque log peut donc être

- Committed (*appliqué*)
- Pending (*pas encore appliqué*)

La machine d'état elle-même

L'état actuel, après application de tous les logs committed.



Log vs Machine d'état

Deux concepts distincts

Le log d'opérations


Ce qui va être (ou a été) appliqué
à la machine d'état

Chaque log peut donc être

- Committed (*appliqué*)
- Pending (*pas encore appliqué*)

La machine d'état elle-même

L'état actuel, après application de
tous les logs committed.



Le leader qui synchronise


Leader




Follower




Le leader qui synchronise




Le leader qui synchronise




Le leader qui synchronise




Le leader qui synchronise




Le leader qui synchronise



Le leader qui synchronise



Le leader qui synchronise



Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
- Je broadcast un message **LogThis** (*AppendEntry*)

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
- Je broadcast un message **LogThis** (*AppendEntry*)
- J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
- Je broadcast un message **LogThis** (*AppendEntry*)
- J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins
- J'applique l'opération à la machine d'état

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
- Je broadcast un message **LogThis** (*AppendEntry*)
- J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins
- J'applique l'opération à la machine d'état
- Je marque l'opération comme *committed*

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
- Je broadcast un message **LogThis** (*AppendEntry*)
- J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins
- J'applique l'opération à la machine d'état
- Je marque l'opération comme *committed*
- J'en informe tout le monde par un **Confirm**

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
- Je broadcast un message **LogThis** (*AppendEntry*)
- J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins
- J'applique l'opération à la machine d'état
- Je marque l'opération comme *committed*
- J'en informe tout le monde par un **Confirm**

Pour tout message, penser un envoi RR ; je réessaie jusqu'à confirmation de réception.

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
- Je broadcast un message **LogThis** (*AppendEntry*)
- J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins ————— *Pourquoi pas tous ?
On y reviendra*
- J'applique l'opération à la machine d'état
- Je marque l'opération comme *committed*
- J'en informe tout le monde par un **Confirm**

Pour tout message, penser un envoi RR ; je réessaie jusqu'à confirmation de réception.

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
 - Je broadcast un message **LogThis** (*AppendEntry*)
 - J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins
 - J'applique l'opération à la machine d'état
 - Je marque l'opération comme *committed*
 - J'en informe tout le monde par un **Confirm**
- | | | |
|--|---|-----------------------|
| | | |
| | — | Pourquoi pas tous ? |
| | | On y reviendra |
| | — | En cas de panne ici ? |
| | | On y reviendra |

Pour tout message, penser un envoi RR ; je réessaie jusqu'à confirmation de réception.

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
 - Je broadcast un message **LogThis** (*AppendEntry*)
 - J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins
 - J'applique l'opération à la machine d'état
 - Je marque l'opération comme *committed*
 - J'en informe tout le monde par un **Confirm**
- Pourquoi pas tous ?
On y reviendra

En cas de panne ici ?
On y reviendra

Pour tout message, penser un envoi RR ; je réessaie jusqu'à confirmation de réception.

En tant que follower,

À la réception d'un LogThis

- Je log localement comme *pending*

Le leader qui synchronise

Le leader reçoit les requêtes d'opérations, et assure leur application chez tous.

En tant que leader,

À la réception d'une requête

- Je la log localement comme *pending*
 - Je broadcast un message **LogThis** (*AppendEntry*)
 - J'attends le ACK d'au moins $\lceil N/2 \rceil + 1$ voisins
 - J'applique l'opération à la machine d'état
 - Je marque l'opération comme *committed*
 - J'en informe tout le monde par un **Confirm**
- Pourquoi pas tous ?
On y reviendra

En cas de panne ici ?
On y reviendra

Pour tout message, penser un envoi RR ; je réessaie jusqu'à confirmation de réception.

En tant que follower,

À la réception d'un LogThis

- Je log localement comme *pending*

À la réception d'un Confirm

- Je marque l'opération *committed*
- Je l'applique à la machine d'état



Élection

Un algorithme spécialisé

Panne du leader

Une panne de leader doit déclencher une nouvelle élection.

Comment faire ?

Panne du leader

Une panne de leader doit déclencher une nouvelle élection.

Comment faire ?

Détection de pannes :

- Le leader envoie un heartbeat régulier à tous les followers.

- Un follower déclenche une élection s'il ne reçoit rien avant un timeout.

Panne du leader

Une panne de leader doit déclencher une nouvelle élection.

Comment faire ?

Détection de pannes :

- Le leader envoie un heartbeat régulier à tous les followers.

- Un follower déclenche une élection s'il ne reçoit rien avant un timeout.

Problème :

Comment déterminer le leader ?

Panne du leader

Problème :

Comment déterminer le leader ?


Panne du leader

Problème :


Comment déterminer le leader ?

Deux processus peuvent être en désaccord sur l'état de leur machine.

Follower 1



Follower 2




Panne du leader

Problème :


Comment déterminer le leader ?

Deux processus peuvent être en désaccord sur l'état de leur machine.

Follower 1



→ Follower 2



Celui ayant le log *committed* le plus récent doit gagner.


Panne du leader

Problème :


Comment déterminer le leader ?

Deux processus peuvent être en désaccord sur l'état de leur machine.

Follower 1




→ Follower 2




Celui ayant le log *committed* le plus récent doit gagner.

Et en cas d'égalité sur les logs *committed* ?

Follower 1



Follower 2




Panne du leader

Problème :


Comment déterminer le leader ?

Deux processus peuvent être en désaccord sur l'état de leur machine.

Follower 1




→ Follower 2




Celui ayant le log *committed* le plus récent doit gagner.

Et en cas d'égalité sur les logs *committed* ?

Follower 1



→ Follower 2



Celui ayant le log *pending* le plus récent doit gagner.

Panne du leader

Problème :

Comment déterminer le leader ?


Panne du leader

Problème :


Comment déterminer le leader ?

Et en cas de désaccord sur les logs *pending* ?

Follower 1



Follower 2




Panne du leader

Problème :


Comment déterminer le leader ?

Et en cas de désaccord sur les logs *pending* ?

Follower 1



Follower 2



Impossible : le leader envoie les messages dans le même ordre à tous.*

*En réalité un peu plus compliqué que ça en cas de gros ralentissements du réseau ; ignoré ici par soucis de simplicité.


Panne du leader

Problème :


Comment déterminer le leader ?

Et en cas de désaccord sur les logs *pending* ?

Follower 1



Follower 2




Impossible : le leader envoie les messages dans le même ordre à tous.*


*En réalité un peu plus compliqué que ça en cas de gros ralentissements du réseau ; ignoré ici par soucis de simplicité.

Et en cas de log *committed* plus ancien, mais *pending* plus récent ?

Follower 1



Follower 2




Panne du leader

Problème :


Comment déterminer le leader ?

Et en cas de désaccord sur les logs *pending* ?

Follower 1



Follower 2




Impossible : le leader envoie les messages dans le même ordre à tous.*


*En réalité un peu plus compliqué que ça en cas de gros ralentissements du réseau ; ignoré ici par soucis de simplicité.

Et en cas de log *committed* plus ancien, mais *pending* plus récent ?

Follower 1



Follower 2




Impossible : le leader envoie les messages dans le même ordre à tous.

Un algorithme spécialisé


Un algorithme spécialisé

Détection de panne du leader



Un algorithme spécialisé


Détection de panne du leader



Réception d'une première candidature


...étant plus (ou autant) à jour que moi

"Je candidate, voici mes logs"




Un algorithme spécialisé

Détection de panne du leader




Réception d'une première candidature

...étant plus (ou autant) à jour que moi




Un algorithme spécialisé

Détection de panne du leader



Réception d'une première candidature


...étant plus (ou autant) à jour que moi



Remarque : je n'ai qu'un seul vote à donner par élection. Premier arrivé, premier servi.


Un algorithme spécialisé

Détection de panne du leader



Réception d'une première candidature

...étant plus (ou autant) à jour que moi




...étant moins à jour que moi



Remarque : je n'ai qu'un seul vote à donner par élection. Premier arrivé, premier servi.


Un algorithme spécialisé

Détection de panne du leader




Réception d'une première candidature

...étant plus (ou autant) à jour que moi




...étant moins à jour que moi



Remarque : je n'ai qu'un seul vote à donner par élection. Premier arrivé, premier servi.

Un algorithme spécialisé

Détection de panne du leader




Réception de votes


*Si je reçois une majorité de votes,
Je me considère élu leader !*

Réception d'une première candidature

...étant plus (ou autant) à jour que moi




...étant moins à jour que moi



Remarque : je n'ai qu'un seul vote à donner par élection. Premier arrivé, premier servi.

Un algorithme spécialisé

Détection de panne du leader




Réception de votes

*Si je reçois une majorité de votes,
Je me considère élu leader !*


Problème ?

Réception d'une première candidature

...étant plus (ou autant) à jour que moi



...étant moins à jour que moi



Remarque : je n'ai qu'un seul vote à donner par élection. Premier arrivé, premier servi.

Premier arrivé, premier servi ?


Un problème...

Et si tout le monde a les mêmes logs, et détecte la panne en même temps ?

Premier arrivé, premier servi ?

Un problème...


Et si tout le monde a les mêmes logs, et détecte la panne en même temps ?



Premier arrivé, premier servi ?

Un problème...

Et si tout le monde a les mêmes logs, et détecte la panne en même temps ?




Personne n'aura de majorité absolue...

Premier arrivé, premier servi ?

Solution : l'aléatoire !


Les timeouts sont d'une durée aléatoire.



Premier arrivé, premier servi ?

Solution : l'aléatoire !


Les timeouts sont d'une durée aléatoire.



Premier arrivé, premier servi ?

Solution : l'aléatoire !


Les timeouts sont d'une durée aléatoire.



Premier arrivé, premier servi ?

Solution : l'aléatoire !


Les timeouts sont d'une durée aléatoire.



Premier arrivé, premier servi ?

Solution : l'aléatoire !

Les timeouts sont d'une durée aléatoire.




Celui qui timeout en premier a plus de chances d'être élu !

Premier arrivé, premier servi ?

Solution : l'aléatoire !

Les timeouts sont d'une durée aléatoire.



Celui qui timeout en premier a plus de chances d'être élu !

Problème ?

Premier arrivé, premier servi ?

Problème : l'aléatoire !

Et si l'aléatoire ne suffit pas ?

Premier arrivé, premier servi ?

Problème : l'aléatoire !

Et si l'aléatoire ne suffit pas ?

Alors

Personne ne se considèrera élu, donc

Personne n'enverra de heartbeat, donc

Tout le monde va à nouveau timeout.

Autrement dit, les élections s'enchaîneront jusqu'à ce qu'un élu soit trouvé.

Premier arrivé, premier servi

Résumé

Le leader envoie un heartbeat régulier à tous les followers.
Chaque processus a une durée de *timeout d'élection*.

Premier arrivé, premier servi

Résumé

Le leader envoie un heartbeat régulier à tous les followers.
Chaque processus a une durée de *timeout d'élection*.

En tant que follower,

Si aucun heartbeat pendant ma durée de timeout

- Je deviens candidat aux prochaines élections
- J'envoie ma candidature à tout le monde, avec mes logs récents

Premier arrivé, premier servi

Résumé

Le leader envoie un heartbeat régulier à tous les followers.
Chaque processus a une durée de *timeout d'élection*.

En tant que follower,

Si aucun heartbeat pendant ma durée de timeout

- Je deviens candidat aux prochaines élections
- J'envoie ma candidature à tout le monde, avec mes logs récents

Si je reçois une candidature

- Si j'ai des logs pending (à défaut, committed) plus récents que lui, je l'ignore
- Sinon, si c'est la première candidature valide pour ce mandat
 - Je l'accepte et lui envoie mon vote

Premier arrivé, premier servi

Résumé

Le leader envoie un heartbeat régulier à tous les followers.
Chaque processus a une durée de *timeout d'élection*.

En tant que follower,

Si aucun heartbeat pendant ma durée de timeout

- Je deviens candidat aux prochaines élections
- J'envoie ma candidature à tout le monde, avec mes logs récents

Si je reçois une candidature

- Si j'ai des logs pending (à défaut, committed) plus récents que lui, je l'ignore
- Sinon, si c'est la première candidature valide pour ce mandat
 - Je l'accepte et lui envoie mon vote

Si je suis candidat et reçois une majorité de votes

- Je deviens le leader

Désaccord avec l'élu ?

Un follower peut-il avoir un log *committed* que l'élu n'a pas ?

Désaccord avec l'élus ?

Un follower peut-il avoir un log *committed* que l'élus n'a pas ?

Si oui,

Un message `Confirm` aurait été reçu pour ce log, donc

Le leader aurait reçu une majorité de `ACK` pour ce log, donc

Une majorité de processus possèderaient ce log, donc

Une majorité de processus n'auraient pas voté pour cet élu.

Donc impossible

Désaccord avec l'élus ?

Un follower peut-il avoir un log *committed* que l'élus n'a pas ?

Si oui,

Un message Confirm aurait été reçu pour ce log, donc

Le leader aurait reçu une majorité de ACK pour ce log, donc

Une majorité de processus possèderaient ce log, donc

Une majorité de processus n'auraient pas voté pour cet élu.

Donc impossible

Un follower peut-il avoir un log *pending* que l'élus n'a pas ?

Désaccord avec l' élu ?

Un follower peut-il avoir un log *committed* que l' élu n'a pas ?

Si oui,

*Un message *Confirm* aurait été reçu pour ce log, donc*

*Le leader aurait reçu une majorité de *ACK* pour ce log, donc*

Une majorité de processus possèderaient ce log, donc

Une majorité de processus n'auraient pas voté pour cet élu.

Donc impossible


Un follower peut-il avoir un log *pending* que l' élu n'a pas ?

Oui, en cas de panne...


↓ Pannes du leader

Quand tout se complique (?)

Panne durant un LogThis




Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Panne durant un LogThis




Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

Panne durant un LogThis



Problème ?


Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

S'il avait reçu LogThis:C,

Il fait ajouter C à tous les followers

Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.


Que doit faire le prochain leader ?

S'il avait reçu LogThis:C,

Il fait ajouter C à tous les followers

Sinon

Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?


S'il avait reçu LogThis:C,

Il fait ajouter C à tous les followers

Sinon

*Il fait **retirer** C à tous les followers*

Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

S'il avait reçu LogThis:C,


Il fait ajouter C à tous les followers

Sinon

*Il fait **retirer** C à tous les followers* ← c sera perdu, mais c'est OK.

Pourquoi ?

Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

S'il avait reçu LogThis:C,

Il fait ajouter C à tous les followers

Sinon


*Il fait **retirer** C à tous les followers* ← C sera perdu, mais c'est OK.

Pourquoi ?

Le leader est tombé en panne pendant le traitement de C.

L'ignorer n'est donc pas incohérent.

Panne durant un LogThis




Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

Le leader demandera à tous les followers d'écraser leurs logs par les siens.

Panne durant un LogThis



Problème ?


Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

Le leader demandera à tous les followers d'écraser leurs logs par les siens.

Risque d'écraser un log *committed* ?

Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?


Le leader demandera à tous les followers d'écraser leurs logs par les siens.

Risque d'écraser un log *committed* ?

Non

On a vu qu'aucun follower ne peut avoir un log committed que le leader n'a pas.

Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

Le leader demandera à tous les followers d'écraser leurs logs par les siens.


Risque d'écraser un log *committed* ?

Non

On a vu qu'aucun follower ne peut avoir un log committed que le leader n'a pas.

Risque d'écraser un log *pending* ?

Panne durant un LogThis



Problème ?

Ce log ne sera *committed* chez personne.
Pas de désaccord sur l'état de la machine.
Mais, désaccord possible sur les *pending*.

Que doit faire le prochain leader ?

Le leader demandera à tous les followers d'écraser leurs logs par les siens.

Risque d'écraser un log *committed* ?

Non


On a vu qu'aucun follower ne peut avoir un log committed que le leader n'a pas.

Risque d'écraser un log *pending* ?

Oui


Si une minorité avait reçu ce log, il est possible qu'aucune d'entre elles n'ait été élue. Dans ce cas, ce log sera perdu. C'est OK.

Panne durant un Confirm



Problème ?


Panne durant un Confirm



Problème ?

Une majorité aura reçu `LogThis:C`,
Donc l'élu aura C parmi ses logs,
Mais peut-être seulement en *pending*.

Panne durant un Confirm




Problème ?

Une majorité aura reçu `LogThis:C`,
Donc l'élu aura C parmi ses logs,
Mais peut-être seulement en *pending*.

Si C est *committed* chez le nouveau leader

Panne durant un Confirm




Problème ?

Une majorité aura reçu `LogThis:C`,
Donc l'élu aura C parmi ses logs,
Mais peut-être seulement en *pending*.

Si C est *committed* chez le nouveau leader

Il demande à tous les followers de le commit, si pas déjà fait.

Panne durant un Confirm



Problème ?


Une majorité aura reçu `LogThis:C`,
Donc l'élu aura C parmi ses logs,
Mais peut-être seulement en *pending*.

Si C est *committed* chez le nouveau leader

Il demande à tous les followers de le commit, si pas déjà fait.

Si C est *pending* chez le nouveau leader

Panne durant un Confirm



Problème ?

Une majorité aura reçu `LogThis:C`,
Donc l'élue aura C parmi ses logs,
Mais peut-être seulement en *pending*.


Si C est *committed* chez le nouveau leader

Il demande à tous les followers de le commit, si pas déjà fait.

Si C est *pending* chez le nouveau leader

Il demande à tous les followers de le logger, si pas déjà fait.

Panne durant un Confirm



Problème ?

Une majorité aura reçu `LogThis:C`,
Donc l'élu aura C parmi ses logs,
Mais peut-être seulement en *pending*.

Si C est *committed* chez le nouveau leader

Il demande à tous les followers de le commit, si pas déjà fait.

Si C est *pending* chez le nouveau leader

Il demande à tous les followers de le logger, si pas déjà fait.

Puis enverra `Confirm:C` une fois qu'une majorité lui aura répondu.

↓ **Résumé**

En résumé

Raft est un consensus spécialisé pour la réplication de machine d'état.

En résumé

Raft est un consensus spécialisé pour la réplication de machine d'état.

Le mécanisme d'**élection** assure

- Un seul leader à la fois

- La gestion des absences de majorité (*via timeouts aléatoires*)

- L'élection d'un processus à jour avec la majorité des autres

En résumé

Raft est un consensus spécialisé pour la réplication de machine d'état.

Le mécanisme d'**élection** assure

- Un seul leader à la fois

- La gestion des absences de majorité (*via timeouts aléatoires*)

- L'élection d'un processus à jour avec la majorité des autres

Le mécanisme de **réplication des logs** assure

- Un consensus sur les logs (via le leader central)

- Une reprise par le prochain leader là où l'autre est mort

En résumé

Raft est un consensus spécialisé pour la réplication de machine d'état.

Le mécanisme d'**élection** assure

- Un seul leader à la fois

- La gestion des absences de majorité (*via timeouts aléatoires*)

- L'élection d'un processus à jour avec la majorité des autres

Le mécanisme de **réplication des logs** assure

- Un consensus sur les logs (via le leader central)

- Une reprise par le prochain leader là où l'autre est mort

La limite des $\lceil N/2 \rceil - 1$ pannes est essentielle

- Un log n'est *committed* que quand une majorité en a connaissance

- Une majorité doit accepter les logs d'un candidat pour l'élire

- Il suffit donc d'une majorité de processus corrects pour avancer

Les propriétés formelles

Les propriétés formelles

Unicité du leader

Un seul leader à la fois

Les propriétés formelles

Unicité du leader

Un seul leader à la fois

Progrès uniquement

Un leader ne peut qu'ajouter à ses logs, pas en supprimer. Ce qui est fait est fait.

Les propriétés formelles

Unicité du leader

Un seul leader à la fois

Progrès uniquement

Un leader ne peut qu'ajouter à ses logs, pas en supprimer. Ce qui est fait est fait.

Équivalence des logs

Si deux processus ont un même log, tous leurs logs précédents sont identiques.

Les propriétés formelles

Unicité du leader

Un seul leader à la fois

Progrès uniquement

Un leader ne peut qu'ajouter à ses logs, pas en supprimer. Ce qui est fait est fait.

Équivalence des logs

Si deux processus ont un même log, tous leurs logs précédents sont identiques.

Complétude du leader

Si un leader possède un log *committed*, les prochains leaders l'auront aussi.

Les propriétés formelles

Unicité du leader

Un seul leader à la fois

Progrès uniquement

Un leader ne peut qu'ajouter à ses logs, pas en supprimer. Ce qui est fait est fait.

Équivalence des logs

Si deux processus ont un même log, tous leurs logs précédents sont identiques.

Complétude du leader

Si un leader possède un log *committed*, les prochains leaders l'auront aussi.

Validité de la machine d'état

Si un leader applique une opération à sa machine d'état, alors aucun autre processus ne peut appliquer une autre opération pour le même log.